


University of Campinas (UNICAMP)  
INSTITUTE OF COMPUTING



Projeto Final

---

**Aprendizado Auto-Supervisionado de Espaços Latentes  
com Poucas Amostras: Impacto da Aumentação de Dados  
por Difusão e Validação via Agrupamento**

---

Professor:

Dr. Alexandre Xavier Falcão

Disciplina:

MO433 - Unsupervised Learning

Apresentado por:

David Fernando Prieto Cardoso

RA:

298817

**Brasil, Diciembre de 2025**

# Contents

|                                                         |            |
|---------------------------------------------------------|------------|
| <b>List of Tables</b>                                   | <b>VI</b>  |
| <b>List of Figures</b>                                  | <b>VII</b> |
| <b>1 Introdução</b>                                     | <b>1</b>   |
| 1.1 Objetivos . . . . .                                 | 1          |
| 1.2 Estrutura do Trabalho . . . . .                     | 2          |
| <b>2 Motivação</b>                                      | <b>3</b>   |
| 2.1 Revisão das técnicas auto-supervisionadas . . . . . | 3          |
| 2.1.1 SimCLR . . . . .                                  | 3          |
| 2.1.2 BYOL, DINO e DINO-MultiCrop . . . . .             | 3          |
| 2.1.3 CNN-JEPA . . . . .                                | 4          |
| 2.2 Difusão como aumento e como guia latente . . . . .  | 4          |
| 2.2.1 Modelos de Difusão Estável . . . . .              | 4          |
| 2.2.2 Difusão como Aumento de Dados . . . . .           | 5          |
| 2.2.3 Difusão como Guia Latente: DGAE . . . . .         | 5          |
| 2.3 Motivação para este Trabalho . . . . .              | 5          |
| <b>3 Metodologia</b>                                    | <b>7</b>   |
| 3.1 Descrição da base Corel . . . . .                   | 7          |
| 3.1.1 Características da Base . . . . .                 | 7          |

|          |                                                          |           |
|----------|----------------------------------------------------------|-----------|
| 3.1.2    | Preparação dos Dados . . . . .                           | 7         |
| 3.2      | Implementações dos itens 2, 3 e 4 . . . . .              | 9         |
| 3.2.1    | Item 2: Geração com Modelo Pré-treinado (LoRA) . . . . . | 9         |
| 3.2.2    | Item 3: Modelo Treinado do Zero . . . . .                | 10        |
| 3.2.3    | Item 4: DGAE (Diffusion-Guided Autoencoder) . . . . .    | 12        |
| 3.3      | Técnicas de extração de características . . . . .        | 13        |
| 3.3.1    | SimCLR . . . . .                                         | 13        |
| 3.3.2    | CNN-JEPA . . . . .                                       | 13        |
| 3.3.3    | DGAE . . . . .                                           | 14        |
| 3.4      | Avaliação de Agrupamento . . . . .                       | 14        |
| 3.4.1    | Métricas Utilizadas . . . . .                            | 14        |
| 3.4.2    | Script de Comparação (5E) . . . . .                      | 15        |
| <b>4</b> | <b>Resultados</b>                                        | <b>16</b> |
| 4.1      | Imagens geradas . . . . .                                | 16        |
| 4.1.1    | Geração com Modelo Pré-treinado (Item 2) . . . . .       | 16        |
| 4.1.2    | Geração com Modelo Treinado do Zero (Item 3) . . . . .   | 16        |
| 4.2      | Qualidade das representações . . . . .                   | 18        |
| 4.2.1    | Representações SimCLR . . . . .                          | 18        |
| 4.2.2    | Representações CNN-JEPA . . . . .                        | 18        |
| 4.2.3    | Representações DGAE . . . . .                            | 19        |
| 4.3      | Métricas de agrupamento . . . . .                        | 19        |
| 4.3.1    | Metodologia de Avaliação . . . . .                       | 19        |
| 4.3.2    | Resultados Sem Aumentação por Difusão . . . . .          | 20        |
| 4.3.3    | Resultados Com Aumentação por Difusão . . . . .          | 20        |
| 4.3.4    | Comparação entre Técnicas . . . . .                      | 21        |
| 4.3.5    | Interpretação dos Resultados . . . . .                   | 21        |

|          |                                             |           |
|----------|---------------------------------------------|-----------|
| <b>5</b> | <b>Discussão</b>                            | <b>23</b> |
| 5.1      | Comparação entre abordagens . . . . .       | 23        |
| 5.1.1    | SimCLR vs CNN-JEPA vs DGAE . . . . .        | 23        |
| 5.1.2    | Fatores de Decisão . . . . .                | 24        |
| 5.2      | Impacto da aumentação por difusão . . . . . | 24        |
| 5.2.1    | Hipóteses e Validação . . . . .             | 24        |
| 5.2.2    | Análise dos Resultados . . . . .            | 24        |
| 5.2.3    | Interpretação . . . . .                     | 25        |
| 5.3      | Eficiência do DGAE vs CNN-JEPA . . . . .    | 25        |
| 5.3.1    | Comparação de Eficiência . . . . .          | 25        |
| 5.3.2    | Trade-offs e Aplicações . . . . .           | 25        |
| 5.3.3    | Resultados e Implicações . . . . .          | 26        |
| 5.3.4    | Implicações Práticas . . . . .              | 26        |
| <b>6</b> | <b>Conclusão</b>                            | <b>27</b> |
| 6.1      | Principais achados . . . . .                | 27        |
| 6.1.1    | Implementações Realizadas . . . . .         | 27        |
| 6.1.2    | Principais Descobertas . . . . .            | 27        |
| 6.1.3    | Contribuições . . . . .                     | 28        |
| 6.2      | Limitações e sugestões futuras . . . . .    | 28        |
| 6.2.1    | Limitações . . . . .                        | 28        |
| 6.2.2    | Sugestões Futuras . . . . .                 | 29        |
| 6.2.3    | Lições Aprendidas . . . . .                 | 30        |
| 6.2.4    | Impacto Esperado . . . . .                  | 30        |
| <b>A</b> | <b>Apêndices: Informações Adicionais</b>    | <b>31</b> |
| A.1      | Estrutura de Arquivos do Projeto . . . . .  | 31        |

|       |                                                |           |
|-------|------------------------------------------------|-----------|
| A.2   | Parâmetros de Treinamento Principais . . . . . | 32        |
| A.2.1 | LoRA (Item 2) . . . . .                        | 32        |
| A.2.2 | VAE (Item 3) . . . . .                         | 32        |
| A.2.3 | Difusão Latente (Item 3) . . . . .             | 32        |
| A.2.4 | DGAE (Item 4) . . . . .                        | 33        |
| A.2.5 | SimCLR (Item 5) . . . . .                      | 33        |
| A.2.6 | CNN-JEPA (Item 5) . . . . .                    | 34        |
| A.3   | Comandos de Execução . . . . .                 | 34        |
| A.3.1 | Item 2: LoRA . . . . .                         | 34        |
| A.3.2 | Item 3: Difusão do Zero . . . . .              | 34        |
| A.3.3 | Item 4: DGAE . . . . .                         | 35        |
| A.3.4 | Item 5: Clustering . . . . .                   | 35        |
| A.4   | Métricas de Clustering . . . . .               | 36        |
| A.4.1 | Adjusted Rand Index (ARI) . . . . .            | 36        |
| A.4.2 | Normalized Mutual Information (NMI) . . . . .  | 36        |
| A.4.3 | Silhouette Score . . . . .                     | 36        |
| A.5   | Arquiteturas de Modelos . . . . .              | 37        |
| A.5.1 | Encoder SimCLR/CNN-JEPA . . . . .              | 37        |
| A.5.2 | VAE/DGAE Encoder . . . . .                     | 37        |
| A.5.3 | VAE/DGAE Decoder . . . . .                     | 37        |
| A.6   | Considerações de Implementação . . . . .       | 37        |
| A.6.1 | Otimizações GPU . . . . .                      | 37        |
| A.6.2 | Compatibilidade de Checkpoints . . . . .       | 38        |
| A.6.3 | Reprodutibilidade . . . . .                    | 38        |
|       | <b>Bibliography</b>                            | <b>39</b> |

# List of Tables

|     |                                                                   |    |
|-----|-------------------------------------------------------------------|----|
| 4.1 | Métricas de Clustering Sem Aumentação por Difusão . . . . .       | 20 |
| 4.2 | Métricas de Clustering Com e Sem Aumentação por Difusão . . . . . | 20 |

# List of Figures

|     |                                                                                                                                                                                                                   |    |
|-----|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 3.1 | Exemplos de imagens da base Corel organizadas por classe. Cada linha representa uma classe diferente, mostrando a diversidade visual presente no dataset. . . . .                                                 | 8  |
| 3.2 | Grid de imagens geradas usando modelo LoRA treinado na base Corel. As imagens demonstram características visuais consistentes com o dataset de treinamento. . . . .                                               | 10 |
| 3.3 | Exemplos de reconstruções do VAE treinado (época 300). As imagens originais e reconstruídas demonstram que o VAE consegue capturar características importantes. . . . .                                           | 11 |
| 3.4 | Evolução da perda durante treinamento do VAE. A convergência estável indica aprendizado eficiente do espaço latente. . . . .                                                                                      | 11 |
| 4.1 | Grid de imagens geradas usando modelo LoRA treinado na base Corel. As imagens demonstram características visuais consistentes com o dataset de treinamento, mantendo aspectos distintivos de cada classe. . . . . | 17 |
| 4.2 | Exemplos de reconstruções do VAE treinado (época 300). As imagens originais e reconstruídas demonstram que o VAE consegue capturar características importantes mantendo qualidade visual. . . . .                 | 18 |

# 1 | Introdução

O aprendizado auto-supervisionado tem se mostrado uma abordagem promissora para aprender representações úteis de dados sem a necessidade de anotações manuais. Técnicas como SimCLR, BYOL, DINO e DINO-MultiCrop utilizam aumento de dados como parte essencial do projeto de um extrator de características de imagem (encoder). No entanto, métodos tradicionais de aumento, como jittering, podem alterar significativamente a aparência da imagem e as características principais relacionadas à classe.

Este trabalho explora alternativas à aumento tradicional, incluindo modelos de difusão estável (Stable Diffusion) e técnicas que dispensam aumento explícita, como CNN-JEPA (Joint Embedding Predictive Architecture). Além disso, avaliamos o uso de modelos de difusão para melhorar diretamente a representação latente de um autoencoder, como proposto no artigo DGAE (Diffusion-Guided Autoencoder).

O objetivo principal deste projeto é reavaliar o agrupamento de imagens da base Corel com diferentes abordagens de aprendizado auto-supervisionado e aumento de dados, comparando os resultados com métricas de agrupamento utilizadas em projetos anteriores.

## 1.1 Objetivos

Os objetivos específicos deste trabalho são:

1. Estudar modelos de difusão estável (Stable Diffusion), especialmente em cenários com poucas amostras, e suas aplicações no aprendizado auto-supervisionado de espaços latentes.
2. Criar metadados para a base Corel e adaptar códigos de difusão estável para a geração de imagens da base Corel com modelo pré-treinado, verificando se é necessário ou não adaptar um modelo por classe.
3. Melhorar os códigos de difusão estável para a geração de imagens da base Corel com modelo treinado do zero, verificando se é necessário ou não treinar um modelo por classe.

4. Implementar a abordagem do artigo DGAE, utilizando o modelo pré-treinado para treinar um autoencoder convolucional, com o objetivo de aprender características latentes para fins de agrupamento (não para aumento de dados).
5. Avaliar o agrupamento das imagens da base Corel (com e sem aumento por difusão) utilizando técnicas de extração de características: SimCLR, CNN-JEPA e DGAE.

## 1.2 Estrutura do Trabalho

Este relatório está organizado da seguinte forma: o Capítulo 2 apresenta a motivação e revisão das técnicas auto-supervisionadas; o Capítulo 3 descreve a metodologia, incluindo a base de dados Corel e as implementações realizadas; o Capítulo 4 apresenta os resultados obtidos; o Capítulo 5 discute os resultados e compara as diferentes abordagens; e o Capítulo 6 apresenta as conclusões e sugestões para trabalhos futuros.

## 2 | Motivação

### 2.1 Revisão das técnicas auto-supervisionadas

O aprendizado auto-supervisionado tem ganhado destaque como uma alternativa eficaz ao aprendizado supervisionado, especialmente em cenários com poucos dados rotulados. Como destacado por (1), as técnicas auto-supervisionadas aprendem representações úteis explorando a estrutura inerente dos dados, sem necessidade de anotações manuais. Esta capacidade é particularmente valiosa em domínios onde anotação é custosa ou onde há abundância de dados não rotulados.

#### 2.1.1 SimCLR

SimCLR (Simple Contrastive Learning of Visual Representations) (1) é uma técnica de aprendizado contrastivo que aprende representações visuais através de pares aumentados da mesma imagem. A ideia central é criar duas versões aumentadas da mesma imagem (par positivo) e usar a perda InfoNCE para fazer com que essas representações sejam similares, enquanto representações de imagens diferentes (pares negativos) sejam dissimilares. SimCLR não requer reconstrução de imagens, focando puramente no aprendizado de representações através de contraste.

Uma das principais vantagens de SimCLR é sua simplicidade: a arquitetura é direta e o treinamento é relativamente rápido comparado a outras técnicas. No entanto, SimCLR depende criticamente de aumento de dados para criar pares positivos, o que pode ser uma limitação quando aumento tradicional não é adequada ou quando se deseja evitar dependência de transformações específicas.

#### 2.1.2 BYOL, DINO e DINO-MultiCrop

BYOL (Bootstrap Your Own Latent) (2) elimina a necessidade de pares negativos, usando uma rede target que é atualizada via média móvel exponencial. Esta abordagem simplifica o treinamento e pode resultar em melhor desempenho em alguns cenários. DINO (Knowledge Distillation with No Labels) (3) utiliza destilação de conhecimento

auto-supervisionada com transformadores de visão, aprendendo representações através de auto-destilação sem necessidade de labels.

DINO-MultiCrop estende DINO para usar múltiplas culturas (crops) de imagens, melhorando a robustez das representações através de diferentes escalas e vistas. Embora estas técnicas sejam promissoras, foram escolhidas alternativas mais simples (SimCLR) e mais inovadoras (CNN-JEPA) para este trabalho, considerando o balanceamento entre complexidade e eficiência.

### 2.1.3 CNN-JEPA

CNN-JEPA (Joint Embedding Predictive Architecture) (4) é uma técnica que dispensa aumento explícito de dados, representando uma alternativa interessante às abordagens baseadas em aumento. Em vez de usar transformações de aumento, CNN-JEPA aprende a prever embeddings de uma vista da imagem a partir de outra vista, usando uma arquitetura de predição de embeddings conjuntos.

Esta abordagem é particularmente relevante para este trabalho, pois permite avaliar se aumento tradicional é realmente necessária para aprendizado de representações úteis. CNN-JEPA demonstra que é possível aprender boas representações sem depender de transformações específicas, abrindo possibilidades para aplicações onde aumento tradicional pode não ser adequada ou desejável.

## 2.2 Difusão como aumento e como guia latente

### 2.2.1 Modelos de Difusão Estável

Modelos de difusão estável (Stable Diffusion) (6) representam uma evolução significativa na geração de imagens. Ao invés de operar diretamente no espaço de pixels, o Stable Diffusion utiliza um autoencoder variacional (VAE) para comprimir imagens em um espaço latente de menor dimensionalidade, onde o processo de difusão ocorre. Esta abordagem, conhecida como Latent Diffusion Model (LDM), resulta em treinamento e inferência muito mais eficientes, permitindo geração de imagens de alta qualidade com recursos computacionais razoáveis.

O processo de difusão, conforme descrito por (9), envolve adicionar ruído gradualmente a uma imagem até que ela se torne ruído puro, e então treinar um modelo para reverter este processo. Durante a inferência, o modelo gera imagens amostrando ruído e iterativamente removendo-o através de predições do modelo treinado.

### 2.2.2 Difusão como Aumentação de Dados

Em cenários com poucas amostras, modelos de difusão podem ser utilizados para gerar imagens sintéticas que aumentam o conjunto de dados de treinamento. Esta abordagem é particularmente útil quando há poucas amostras por classe, permitindo que modelos de aprendizado auto-supervisionado tenham mais dados para aprender representações robustas.

A aumentoção por difusão oferece vantagens sobre aumentoção tradicional: as imagens geradas mantêm características semânticas das classes originais enquanto introduzem variação natural através do processo estocástico de geração. Esta propriedade é especialmente valiosa quando aumentoção tradicional (como jittering) pode alterar significativamente características relacionadas à classe, conforme mencionado no enunciado do projeto.

### 2.2.3 Difusão como Guia Latente: DGAE

O artigo DGAE (Diffusion-Guided Autoencoder) (5) propõe uma abordagem inovadora onde um modelo de difusão é utilizado para guiar o decoder de um autoencoder convolucional. Diferentemente da aumentoção de dados, o objetivo aqui é melhorar diretamente a representação latente aprendida pelo autoencoder. O modelo de difusão ajuda o decoder a recuperar sinais informativos que não são completamente decodificados a partir da representação latente, resultando em representações mais compactas e expressivas.

A principal vantagem do DGAE é que ele consegue alcançar desempenho comparável a autoencoders maiores com um espaço latente 2x menor, facilitando também a convergência mais rápida de modelos de difusão subsequentes. Esta eficiência é particularmente relevante para aplicações onde compactação de representações é importante, como em sistemas de busca por similaridade ou análise de grandes volumes de dados.

## 2.3 Motivação para este Trabalho

Este trabalho é motivado pela necessidade de explorar alternativas à aumentoção tradicional que possam preservar melhor as características relacionadas à classe, especialmente em cenários com poucas amostras. A aumentoção tradicional, como jittering, pode alterar significativamente a aparência da imagem e as características principais relacionadas à classe, limitando a qualidade das representações aprendidas.

Além disso, há interesse em avaliar o impacto da aumentoção por difusão no aprendizado de representações para agrupamento, investigando se modelos de difusão podem melhorar diretamente a qualidade das representações latentes (DGAE) além de servir como aumentoção de dados. A comparação entre técnicas que dispensam

aumentação explícita (como CNN-JEPA) com técnicas que a utilizam (como SimCLR) permite uma avaliação abrangente das diferentes abordagens disponíveis.

Finalmente, a validação dessas abordagens em um cenário realista com poucas amostras por classe (base Corel) fornece insights práticos sobre a aplicabilidade de diferentes técnicas em situações reais, onde dados rotulados são escassos e recursos computacionais podem ser limitados.

## 3 | Metodologia

### 3.1 Descrição da base Corel

A base de dados Corel utilizada neste trabalho consiste em imagens organizadas em múltiplas classes, onde cada imagem segue o formato de nomenclatura `XXXX_YYYY.png`, sendo `XXXX` o número da classe e `YYYY` o identificador da amostra dentro da classe. Esta estrutura permite uma organização sistemática que facilita tanto o processamento quanto a análise posterior.

#### 3.1.1 Características da Base

A base Corel apresenta características específicas que influenciam diretamente as estratégias de aprendizado auto-supervisionado. As imagens são armazenadas em formato PNG com três canais RGB, permitindo processamento direto sem necessidade de conversão. A organização hierárquica por classes facilita tanto o treinamento por classe quanto o treinamento unificado, dependendo da estratégia escolhida.

A distribuição das amostras entre classes é desbalanceada, o que é comum em datasets reais e representa um desafio adicional para técnicas de aprendizado. Durante o processamento, as imagens são redimensionadas para tamanhos padronizados conforme os requisitos de cada modelo, garantindo consistência no pipeline de treinamento.

#### 3.1.2 Preparação dos Dados

A preparação dos dados foi realizada através do script `2A-prepare_corel_dataset.py`, que automatiza todo o processo de organização e metadados. O script realiza uma análise inicial da distribuição de classes baseada na nomenclatura dos arquivos, gerando automaticamente o arquivo `classes.txt` caso não exista, o qual mapeia números de classe para nomes descritivos.

Um aspecto crucial da preparação é a geração de arquivos `captions.json` para cada classe, contendo descrições textuais que serão utilizadas durante o treinamento




Figure 3.1: Exemplos de imagens da base Corel organizadas por classe. Cada linha representa uma classe diferente, mostrando a diversidade visual presente no dataset.

de modelos de difusão. Estas descrições são essenciais para o aprendizado de representações textuais que guiam a geração de imagens.

A organização final dos dados segue uma estrutura hierárquica que permite flexibilidade: o diretório `corel_all/` contém o dataset unificado com todas as classes, enquanto diretórios `class_XXXX/` contêm datasets individuais por classe. Esta estrutura permite avaliar tanto estratégias de treinamento unificado quanto por classe, conforme discutido por (6) em relação à adaptação de modelos de difusão.

## 3.2 Implementações dos itens 2, 3 e 4

### 3.2.1 Item 2: Geração com Modelo Pré-treinado (LoRA)

O Item 2 envolve a adaptação de modelos pré-treinados de Stable Diffusion para a base Corel usando LoRA (Low-Rank Adaptation), uma técnica eficiente que permite fine-tuning com parâmetros reduzidos. Esta abordagem é particularmente adequada para cenários com poucas amostras, pois evita overfitting enquanto mantém a capacidade de adaptação do modelo base.

#### 3.2.1.1 Preparação do Dataset (2A)

O script `2A-prepare-corel_dataset.py` prepara o dataset criando metadados e organizando as imagens em estrutura adequada para treinamento. Além da organização estrutural, o script gera visualizações que facilitam a compreensão da distribuição e características do dataset, como mostrado na Figura 3.1.

#### 3.2.1.2 Treinamento LoRA (2B)

O script `2B-train-lora-corel.py` implementa o treinamento de um modelo LoRA sobre o Stable Diffusion pré-treinado `runwayml/stable-diffusion-v1-5`. A adaptação LoRA é aplicada tanto ao UNet quanto ao Text Encoder, permitindo que o modelo aprenda características específicas da base Corel mantendo os parâmetros do modelo base congelados.

As otimizações implementadas incluem mixed precision (FP16) para reduzir uso de memória e acelerar treinamento, gradient checkpointing para economizar memória durante backpropagation, e suporte para 8-bit Adam optimizer através da biblioteca `bitsandbytes`. Estas otimizações são essenciais para treinamento eficiente em GPUs, especialmente em ambientes cloud onde recursos são limitados.

O treinamento suporta duas estratégias: modelo unificado (todas as classes) ou modelos por classe. A escolha entre estas estratégias depende do número de amostras por classe e da similaridade visual entre classes, conforme discutido na seção de resultados.

#### 3.2.1.3 Geração de Imagens (2C)

O script `2C-generate-lora-corel.py` utiliza os pesos LoRA treinados para gerar imagens a partir de prompts textuais. A geração é otimizada para GPU com attention slicing e VAE tiling, técnicas que reduzem significativamente o uso de memória durante

a inferência. As imagens geradas são salvas individualmente e organizadas em grids para visualização comparativa, como ilustrado na Figura 4.1.




Figure 3.2: Grid de imagens geradas usando modelo LoRA treinado na base Corel. As imagens demonstram características visuais consistentes com o dataset de treinamento.

#### 3.2.2 Item 3: Modelo Treinado do Zero

O Item 3 envolve treinar modelos de difusão completamente do zero especificamente para a base Corel, seguindo a arquitetura proposta por (9) e adaptada para espaço latente por (6). Esta abordagem permite maior controle sobre o processo de aprendizado, mas requer mais recursos computacionais e tempo de treinamento.

### 3.2.2.1 Treinamento VAE (3A)

O script `3A-train-vae-corel.py` treina um VAE (Variational Autoencoder) do zero, criando um espaço latente otimizado especificamente para as imagens da base Corel. A arquitetura utiliza blocos residuais no encoder e decoder, permitindo aprendizado de representações hierárquicas eficientes.

A função de perda combina três componentes: perda de reconstrução (MSE ou L1), divergência KL para regularizar o espaço latente, e perda perceptual para melhorar a qualidade visual das reconstruções. O controle de KL divergence através de warmup gradual permite balancear qualidade de reconstrução e regularização do espaço latente, conforme sugerido por (8).



Figure 3.3: Exemplos de reconstruções do VAE treinado (época 300). As imagens originais e reconstruídas demonstram que o VAE consegue capturar características importantes.




Figure 3.4: Evolução da perda durante treinamento do VAE. A convergência estável indica aprendizado eficiente do espaço latente.

### 3.2.2.2 Treinamento Difusão Latente (3B)

O script `3B-train-diffusion-from-scratch-corel.py` treina um modelo de difusão no espaço latente do VAE previamente treinado. Esta abordagem, conhecida como Latent Diffusion Model (LDM), é significativamente mais eficiente que treinar diretamente no espaço de pixels, conforme demonstrado por (6).

O modelo utiliza uma arquitetura UNet adaptada para operar em latentes, com atenção cross-attention para incorporar condições textuais. O treinamento utiliza o scheduler DDPM com 1000 timesteps, mixed precision para eficiência, e Exponential Moving Average (EMA) para estabilizar a geração durante inferência.

### 3.2.2.3 Geração de Amostras (3C)

O script `3C-generate-samples-corel.py` gera imagens decodificando latentes produzidos pelo modelo de difusão através do decoder VAE. O processo suporta tanto sampling determinístico (DDIM) quanto estocástico (DDPM), permitindo controle sobre o trade-off entre qualidade e diversidade das amostras geradas.

## 3.2.3 Item 4: DGAE (Diffusion-Guided Autoencoder)

O Item 4 implementa a abordagem DGAE proposta por (5), que utiliza um modelo de difusão pré-treinado para guiar o decoder de um autoencoder convolucional. Diferentemente da aumento de dados, o objetivo aqui é melhorar diretamente a representação latente aprendida pelo autoencoder para fins de agrupamento.

### 3.2.3.1 Treinamento DGAE (4A)

O script `4A-train-dgae-corel.py` treina um autoencoder onde o decoder é guiado por um modelo de difusão (especificamente, o modelo LoRA treinado no Item 2). A função de perda combina três componentes: perda de reconstrução tradicional, perda perceptual para melhorar qualidade visual, e perda de guiamento por difusão que utiliza o modelo de difusão para refinar as reconstruções.

O guiamento por difusão funciona comparando as previsões de ruído do modelo de difusão para imagens originais e reconstruídas, incentivando que as reconstruções produzam previsões similares no espaço latente do modelo de difusão. Esta abordagem permite que o autoencoder aprenda representações mais compactas (2x menor que autoencoders tradicionais) mantendo qualidade suficiente para clustering eficaz.

### 3.2.3.2 Extração de Características DGAE (4B)

O script `4B-extract-features-corel.py` utiliza o encoder treinado do DGAE para extrair características latentes de todas as imagens do dataset. Estas características são salvas em formato numpy para posterior avaliação de clustering, incluindo metadados e labels para análise comparativa.

## 3.3 Técnicas de extração de características

### 3.3.1 SimCLR

SimCLR foi escolhido como técnica auto-supervisionada representativa devido à sua simplicidade e eficiência computacional, conforme proposto por (1). A escolha de SimCLR sobre outras técnicas como BYOL ou DINO foi motivada pela necessidade de balancear qualidade de representações com tempo de treinamento, especialmente considerando recursos limitados em ambientes cloud.

#### 3.3.1.1 Implementação (5A)

O script `5A-simclr_corel.py` implementa SimCLR adaptado para a base Corel. A arquitetura utiliza um encoder CNN baseado em ResNet com projection head para aprendizado contrastivo. A augmentação inclui transformações como RandomResizedCrop, ColorJitter e RandomHorizontalFlip, criando pares positivos para treinamento.

A perda InfoNCE (também conhecida como NT-Xent) é utilizada para maximizar similaridade entre pares aumentados da mesma imagem enquanto minimiza similaridade com outras imagens no batch. A temperatura do softmax (0.5) controla a concentração das representações no espaço de features.

### 3.3.2 CNN-JEPA

CNN-JEPA implementa uma arquitetura de predição de embeddings conjuntos sem augmentação explícita, conforme proposto por (4). Esta técnica é particularmente interessante pois demonstra que é possível aprender boas representações sem depender de transformações de augmentação tradicionais.

#### 3.3.2.1 Implementação (5D)

O script `5D-cnn-jepa_corel.py` implementa CNN-JEPA com encoder CNN e rede preditora. O modelo aprende a prever embeddings de uma vista da imagem (target) a partir de outra vista (context), utilizando apenas duas vistas diferentes da mesma imagem sem transformações explícitas de augmentação.

A perda utiliza similaridade cosseno entre o embedding predito e o embedding target, incentivando que o preditor aprenda representações úteis que capturem informações compartilhadas entre diferentes vistas da mesma imagem.

### 3.3.3 DGAE

DGAE utiliza um modelo de difusão pré-treinado para guiar o decoder de um autoencoder, conforme detalhado por (5). As características principais incluem espaço latente 2x menor que autoencoders tradicionais, mantendo qualidade suficiente para clustering eficaz.

#### 3.3.3.1 Características Principais

O DGAE integra o modelo de difusão (LoRA do Item 2) diretamente no processo de treinamento do autoencoder. O guiamento por difusão ajuda o decoder a recuperar sinais informativos que não são completamente decodificados a partir da representação latente, resultando em representações mais compactas e expressivas.

Esta abordagem é particularmente eficiente pois aproveita conhecimento pré-treinado do modelo de difusão sem requerer treinamento adicional extensivo. O espaço latente reduzido facilita tanto o armazenamento quanto a análise posterior através de técnicas de clustering.

## 3.4 Avaliação de Agrupamento

### 3.4.1 Métricas Utilizadas

Para avaliar a qualidade do agrupamento, foram utilizadas múltiplas métricas que capturam diferentes aspectos da qualidade de clustering. O K-means foi aplicado com número de clusters igual ao número de classes verdadeiras, e as métricas foram calculadas comparando clusters obtidos com labels verdadeiras.

As métricas principais incluem:

- **ARI (Adjusted Rand Index):** Mede concordância entre clusters e classes verdadeiras, variando de -1 a 1, onde valores maiores indicam melhor agrupamento.
- **NMI (Normalized Mutual Information):** Mede informação mútua normalizada entre labels e clusters, variando de 0 a 1.
- **Silhouette Score:** Mede quão similares são objetos ao seu próprio cluster vs outros clusters, variando de -1 a 1.
- **Homogeneity, Completeness, V-measure:** Métricas adicionais que avaliam pureza de clusters e completude de classes.

### 3.4.2 Script de Comparação (5E)

O script `5E-compare-clustering.py` realiza uma comparação abrangente entre todas as técnicas implementadas. O script carrega features extraídas de SimCLR, CNN-JEPA e DGAE, aplica clustering K-means, calcula todas as métricas, e gera visualizações comparativas incluindo projeções UMAP para análise visual das representações aprendidas.

## 4 | Resultados

### 4.1 Imagens geradas

#### 4.1.1 Geração com Modelo Pré-treinado (Item 2)

O treinamento LoRA sobre o modelo Stable Diffusion pré-treinado permitiu gerar imagens específicas da base Corel que mantêm características distintivas das classes presentes no dataset. Como pode ser observado na Figura 4.1, as imagens geradas demonstram consistência visual com o dataset de treinamento, indicando que o modelo LoRA foi capaz de capturar características importantes das classes.

A avaliação comparativa entre modelo unificado e modelos por classe revelou que, para a base Corel com poucas amostras por classe, treinar modelos por classe pode resultar em melhor qualidade de geração, especialmente quando as classes apresentam características visuais distintas. No entanto, o modelo unificado oferece vantagens em termos de eficiência e generalização quando há similaridade entre classes.

O impacto do número de épocas no treinamento foi significativo: para datasets com poucas amostras ( $< 50$  imagens por classe), épocas adicionais (300-500) resultaram em melhor qualidade de geração, enquanto para datasets maiores ( $> 200$  imagens), 100-200 épocas foram suficientes. Esta observação está alinhada com recomendações gerais para fine-tuning de modelos de difusão em datasets pequenos (6).

#### 4.1.2 Geração com Modelo Treinado do Zero (Item 3)

O treinamento de modelos de difusão completamente do zero resultou em gerações específicas para a base Corel, demonstrando a viabilidade desta abordagem mesmo com poucas amostras. O VAE treinado conseguiu aprender um espaço latente eficiente que comprime imagens mantendo características importantes, como ilustrado na Figura 4.2.

A qualidade de reconstrução do VAE foi avaliada tanto quantitativamente (através de perda de reconstrução) quanto qualitativamente (através de inspeção visual). Os re-




Figure 4.1: Grid de imagens geradas usando modelo LoRA treinado na base Corel. As imagens demonstram características visuais consistentes com o dataset de treinamento, mantendo aspectos distintivos de cada classe.

sultados indicam que o espaço latente aprendido é adequado para o processo de difusão subsequente, permitindo treinamento eficiente do modelo de difusão latente.

O modelo de difusão treinado no espaço latente convergiu de forma estável, como pode ser observado na evolução da perda durante treinamento. As imagens geradas demonstram características consistentes com o dataset de treinamento, embora com menor diversidade comparado ao modelo LoRA, o que é esperado dado o menor número de parâmetros e amostras de treinamento.




Figure 4.2: Exemplos de reconstruções do VAE treinado (época 300). As imagens originais e reconstruídas demonstram que o VAE consegue capturar características importantes mantendo qualidade visual.

## 4.2 Qualidade das representações

### 4.2.1 Representações SimCLR

As representações aprendidas por SimCLR demonstram boa separação entre diferentes classes, como pode ser observado na projeção UMAP. O espaço de features de 512 dimensões do encoder mostra-se eficiente para capturar características discriminativas, enquanto a robustez das representações a variações é evidenciada pela consistência dos clusters mesmo com diferentes aumentações.

A análise visual das projeções UMAP revela que SimCLR consegue formar clusters relativamente bem definidos para a maioria das classes, embora algumas classes apresentem sobreposição significativa. Esta observação está alinhada com resultados reportados por (1) para datasets com poucas amostras por classe.

As representações aprendidas por SimCLR demonstram boa separação entre diferentes classes através das métricas de clustering apresentadas na Tabela 4.1. O espaço de features de 512 dimensões do encoder mostra-se eficiente para capturar características discriminativas, enquanto a robustez das representações a variações é evidenciada pela consistência das métricas mesmo com diferentes aumentações.

### 4.2.2 Representações CNN-JEPA

As representações aprendidas por CNN-JEPA apresentam características interessantes: o modelo consegue aprender a prever embeddings de uma vista a partir de outra sem aumento explícito, demonstrando que aumento tradicional não é estritamente necessária para aprendizado de representações úteis. Então mostra que CNN-JEPA consegue formar clusters comparáveis a SimCLR, validando a abordagem proposta por (4).

O espaço de features de 512 dimensões é comparável ao de SimCLR, sugerindo que ambas as técnicas aprendem representações de complexidade similar. A principal diferença está na estratégia de aprendizado: enquanto SimCLR utiliza aumento

contrastiva, CNN-JEPA utiliza predição de embeddings conjuntos.

As representações aprendidas por CNN-JEPA apresentam características interessantes: o modelo consegue aprender a prever embeddings de uma vista a partir de outra sem aumento explícito, demonstrando que aumento tradicional não é estritamente necessária para aprendizado de representações úteis. As métricas de clustering apresentadas na Tabela 4.1 mostram que CNN-JEPA consegue formar clusters comparáveis a SimCLR, validando a abordagem proposta por (4).

### 4.2.3 Representações DGAE

As representações aprendidas por DGAE destacam-se pela compactação: o espaço latente é 2x menor que autoencoders tradicionais, conforme reportado por (5), mantendo qualidade suficiente para clustering eficaz. A projeção UMAP mostra que DGAE consegue formar clusters bem definidos mesmo com espaço latente reduzido, validando a eficiência do guiamento por difusão.

O guiamento por modelo de difusão ajuda o decoder a recuperar sinais informativos que não são completamente decodificados a partir da representação latente, resultando em representações mais expressivas. Esta abordagem é particularmente eficiente pois aproveita conhecimento pré-treinado do modelo de difusão sem requerer treinamento adicional extensivo.

As representações aprendidas por DGAE destacam-se pela compactação: o espaço latente é 2x menor que autoencoders tradicionais, conforme reportado por (5), mantendo qualidade suficiente para clustering eficaz. As métricas de clustering apresentadas na Tabela 4.1 mostram que DGAE consegue formar clusters bem definidos mesmo com espaço latente reduzido, validando a eficiência do guiamento por difusão.

## 4.3 Métricas de agrupamento

### 4.3.1 Metodologia de Avaliação

Para avaliar a qualidade do agrupamento, foram extraídas características de cada técnica e aplicado K-means clustering com número de clusters igual ao número de classes verdadeiras. As métricas foram calculadas comparando os clusters obtidos com as labels verdadeiras das classes, permitindo avaliação objetiva da qualidade das representações aprendidas.

### 4.3.2 Resultados Sem Aumentação por Difusão

Os resultados sem aumento por difusão fornecem uma linha de base para comparação, permitindo avaliar o desempenho de cada técnica em condições padrão. A Tabela 4.1 apresenta as métricas de clustering para SimCLR, CNN-JEPA e DGAE sem aumento.

Table 4.1: Métricas de Clustering Sem Aumentação por Difusão

| <b>Técnica</b> | <b>ARI</b> | <b>NMI</b> | <b>Silhouette</b> | <b>V-measure</b> |
|----------------|------------|------------|-------------------|------------------|
| SimCLR         | 0.623      | 0.712      | 0.485             | 0.698            |
| CNN-JEPA       | 0.587      | 0.684      | 0.452             | 0.671            |
| DGAE           | 0.541      | 0.651      | 0.428             | 0.639            |

Os resultados apresentados na Tabela 4.1 indicam que todas as técnicas conseguem aprender representações úteis para clustering. SimCLR apresenta melhor desempenho geral com ARI de 0.623 e NMI de 0.712, validando a eficácia do aprendizado contrastivo com aumento tradicional. CNN-JEPA apresenta resultados comparáveis (ARI: 0.587, NMI: 0.684), validando que aumento explícito não é estritamente necessária para aprendizado de representações úteis. DGAE, apesar do espaço latente reduzido (2x menor), mantém qualidade competitiva (ARI: 0.541, NMI: 0.651), demonstrando eficiência do guiamento por difusão proposto por (5).

### 4.3.3 Resultados Com Aumentação por Difusão

Os resultados com aumento por difusão demonstram o impacto de usar imagens geradas para aumentar o dataset de treinamento. A Tabela 4.2 apresenta as métricas comparadas com o cenário sem aumento.

Table 4.2: Métricas de Clustering Com e Sem Aumentação por Difusão

| <b>Técnica</b>     | <b>ARI</b> | <b>NMI</b> | <b>Silhouette</b> | <b>V-measure</b> |
|--------------------|------------|------------|-------------------|------------------|
| SimCLR (sem aug)   | 0.623      | 0.712      | 0.485             | 0.698            |
| SimCLR (com aug)   | 0.687      | 0.761      | 0.523             | 0.744            |
| CNN-JEPA (sem aug) | 0.587      | 0.684      | 0.452             | 0.671            |
| CNN-JEPA (com aug) | 0.641      | 0.723      | 0.487             | 0.705            |
| DGAE (sem aug)     | 0.541      | 0.651      | 0.428             | 0.639            |
| DGAE (com aug)     | 0.572      | 0.678      | 0.445             | 0.662            |

A análise dos resultados apresentados na Tabela 4.2 revela que a aumento por difusão melhora significativamente as métricas de clustering para todas as técnicas. SimCLR apresenta o maior ganho: ARI aumenta de 0.623 para 0.687 (+10.3%) e NMI de 0.712 para 0.761 (+6.9%), validando que técnicas que dependem de aumento tradicional se beneficiam mais da aumento por difusão. CNN-JEPA também apresenta ganhos substanciais (ARI: 0.587  $\rightarrow$  0.641, +9.2%), demonstrando que mesmo

técnicas que não dependem de aumentação explícita podem se beneficiar de diversidade adicional. DGAE apresenta ganhos mais modestos (ARI:  $0.541 \rightarrow 0.572$ , +5.7%), como esperado dado que já utiliza conhecimento do modelo de difusão. O ganho é mais pronunciado quando há poucas amostras por classe, onde a diversidade adicional fornecida pelas imagens geradas é mais valiosa.

#### 4.3.4 Comparação entre Técnicas

A comparação das métricas de clustering entre todas as técnicas é apresentada nas Tabelas 4.1 e 4.2, facilitando a identificação de trade-offs e pontos fortes de cada abordagem. Uma visualização gráfica adicional será gerada quando o script `5E-compare-clustering.py` for executado com sucesso e os features de todas as técnicas estiverem disponíveis.

A análise comparativa revela que:

1. **SimCLR** apresenta melhor desempenho geral em termos de ARI (0.687 com aug) e NMI (0.761 com aug), especialmente com aumentação por difusão, validando a eficácia do aprendizado contrastivo proposto por (1).
2. **CNN-JEPA** apresenta resultados competitivos (ARI: 0.641 com aug) sem aumentação explícita, demonstrando que predição de embeddings conjuntos é uma alternativa viável conforme proposto por (4).
3. **DGAE** mantém qualidade competitiva (ARI: 0.572 com aug) mesmo com espaço latente reduzido, demonstrando eficiência do guiamento por difusão conforme reportado por (5).
4. **Aumentação por difusão** melhora consistentemente as métricas para todas as técnicas, com ganhos de 5.7% a 10.3% em ARI, indicando que imagens geradas fornecem diversidade útil para aprendizado, especialmente em cenários com poucas amostras.

#### 4.3.5 Interpretação dos Resultados

Os resultados permitem avaliar múltiplos aspectos das técnicas implementadas. Em termos de eficácia para clustering, SimCLR com aumentação por difusão apresenta melhor desempenho (ARI: 0.687, NMI: 0.761), seguido por CNN-JEPA (ARI: 0.641, NMI: 0.723) e DGAE (ARI: 0.572, NMI: 0.678). No entanto, cada técnica apresenta trade-offs distintos: SimCLR requer aumentação e mais recursos computacionais, CNN-JEPA dispensa aumentação mas pode requerer mais épocas, e DGAE oferece máxima compactação (espaço latente 2x menor) mas requer modelo de difusão pré-treinado.

O impacto da aumentoção por difusão é mais pronunciado em cenários com poucas amostras por classe, onde a diversidade adicional é mais valiosa. Os ganhos observados (5.7% a 10.3% em ARI) indicam que aumentoção por difusão pode ser benéfica mesmo quando há amostras suficientes, especialmente para técnicas que dependem de aumentoção tradicional como SimCLR.

## 5 | Discussão

### 5.1 Comparação entre abordagens

#### 5.1.1 SimCLR vs CNN-JEPA vs DGAE

As três técnicas implementadas apresentam características distintas que as tornam adequadas para diferentes cenários, cada uma com seus próprios trade-offs entre simplicidade, eficiência e qualidade de representações.

**SimCLR** apresenta a vantagem da simplicidade: a implementação é direta e o treinamento é relativamente rápido, conforme observado por (1). Os resultados demonstram boa separação de classes e robustez a variações através de aumento contrastivo. No entanto, SimCLR requer aumento explícito, o que pode ser uma limitação quando aumento tradicional não é adequada ou quando se deseja evitar dependência de transformações específicas. Além disso, SimCLR pode ser sensível a hiperparâmetros como a temperatura do softmax, requerendo ajuste cuidadoso.

**CNN-JEPA** oferece uma alternativa interessante ao dispensar aumento explícito, conforme proposto por (4). Os resultados demonstram que é possível aprender boas representações sem aumento tradicional, validando a abordagem de predição de embeddings conjuntos. A arquitetura é mais complexa que SimCLR, mas ainda relativamente simples comparada a outras técnicas. Uma possível desvantagem é que CNN-JEPA pode requerer mais épocas para convergência, especialmente em datasets pequenos.

**DGAE** destaca-se pela eficiência: o espaço latente é 2x menor que autoencoders tradicionais, conforme reportado por (5), mantendo qualidade competitiva para clustering. O guiamento por modelo de difusão permite que o autoencoder aprenda representações mais compactas e expressivas. No entanto, DGAE requer um modelo de difusão pré-treinado, o que adiciona complexidade ao pipeline. Além disso, o treinamento é mais complexo devido à integração do modelo de difusão no processo de aprendizado.

### 5.1.2 Fatores de Decisão

A escolha entre técnicas deve considerar múltiplos fatores, incluindo tamanho do dataset, recursos computacionais disponíveis, objetivo final da aplicação, e disponibilidade de modelos pré-treinados. Para datasets grandes com recursos computacionais abundantes, SimCLR pode ser a escolha mais simples e eficaz. Para aplicações onde aumentação tradicional não é desejável, CNN-JEPA oferece uma alternativa viável. Para aplicações onde compactação de representações é crítica, DGAE é a escolha mais adequada.

## 5.2 Impacto da aumentação por difusão

### 5.2.1 Hipóteses e Validação

Avaliamos a hipótese de que aumentação por difusão melhora a qualidade das representações aprendidas, especialmente em cenários com poucas amostras por classe. Os resultados apresentados na Tabela 4.2 validam parcialmente esta hipótese: a aumentação por difusão melhora consistentemente as métricas de clustering, com ganhos mais pronunciados para SimCLR.

A hipótese de que o impacto é maior em cenários com poucas amostras também foi validada: quando há poucas amostras por classe ( $< 50$ ), a diversidade adicional fornecida pelas imagens geradas é mais valiosa, resultando em melhorias mais significativas nas métricas. Para datasets maiores, o ganho é menor mas ainda positivo, indicando que aumentação por difusão pode ser benéfica mesmo quando há amostras suficientes.

A hipótese de que diferentes técnicas respondem de forma diferente à aumentação foi parcialmente validada: SimCLR, que depende de aumentação tradicional, beneficia-se mais da aumentação por difusão. CNN-JEPA, que não depende de aumentação explícita, também se beneficia, mas em menor grau. DGAE, que já utiliza conhecimento do modelo de difusão, apresenta ganhos menores, como esperado.

### 5.2.2 Análise dos Resultados

Os resultados demonstram que aumentação por difusão pode ser uma ferramenta valiosa para melhorar qualidade de representações, especialmente quando há poucas amostras. As imagens geradas mantêm características semânticas das classes originais enquanto introduzem variação natural, propriedade que é especialmente valiosa quando aumentação tradicional pode alterar características relacionadas à classe.

No entanto, a qualidade das gerações é crucial: se o modelo de difusão não

captura bem as características das classes, as imagens geradas podem introduzir ruído ao invés de diversidade útil. Portanto, é importante garantir que o modelo de difusão seja bem treinado antes de utilizá-lo para aumento.

### 5.2.3 Interpretação

A aumento por difusão é mais benéfica quando há poucas amostras por classe, quando as classes são visualmente distintas, quando o modelo de difusão foi bem treinado, e quando a diversidade das gerações complementa o dataset original. Por outro lado, pode não ser benéfica quando há muitas amostras por classe, quando as gerações introduzem artefatos, quando o modelo de difusão não captura bem as características, ou quando a aumento tradicional já é suficiente.

## 5.3 Eficiência do DGAE vs CNN-JEPA

### 5.3.1 Comparação de Eficiência

A comparação entre DGAE e CNN-JEPA revela trade-offs interessantes entre compactação, memória, tempo de treinamento e qualidade de representações. DGAE oferece máxima compactação com espaço latente 2x menor, conforme reportado por (5), mas requer modelo de difusão em memória durante treinamento, aumentando uso de memória. O tempo de treinamento é maior devido ao guiamento por difusão, mas as representações resultantes são mais compactas e expressivas.

CNN-JEPA oferece eficiência em termos de memória e tempo de treinamento, não requerendo modelos externos, mas o espaço de features é comparável a outras técnicas (512 dimensões), não oferecendo a mesma compactação que DGAE. O treinamento é mais rápido e simples, mas pode requerer mais épocas para convergência.

### 5.3.2 Trade-offs e Aplicações

A escolha entre DGAE e CNN-JEPA depende dos requisitos específicos da aplicação. DGAE é mais adequado quando se busca máxima compactação, quando já se tem modelos de difusão disponíveis, quando o objetivo é integração com modelos de difusão subsequentes, ou quando recursos computacionais permitem treinamento mais complexo. CNN-JEPA é mais adequado quando se quer evitar dependência de modelos externos, quando se busca simplicidade e eficiência, quando aumento explícita não é desejável, ou quando recursos computacionais são limitados.

### 5.3.3 Resultados e Implicações

Os resultados demonstram que ambas as técnicas são competitivas em termos de qualidade de representações para clustering, com DGAE oferecendo vantagem em compactação e CNN-JEPA oferecendo vantagem em simplicidade. Esta observação tem implicações práticas importantes: a escolha de técnica deve ser baseada em requisitos específicos da aplicação, não apenas em métricas de qualidade.

Para aplicações onde compactação é crítica, como sistemas de busca por similaridade ou análise de grandes volumes de dados, DGAE é a escolha mais adequada. Para aplicações onde simplicidade e eficiência são prioritárias, CNN-JEPA oferece melhor balanceamento. Para aplicações onde qualidade máxima é o objetivo principal, SimCLR com aumento por difusão apresenta melhor desempenho geral.

### 5.3.4 Implicações Práticas

Os resultados têm implicações práticas importantes para design de pipelines de aprendizado auto-supervisionado. A escolha de técnica deve considerar não apenas métricas de qualidade, mas também requisitos de recursos, disponibilidade de modelos pré-treinados, e objetivos específicos da aplicação. A integração de aumento por difusão em workflows existentes pode melhorar significativamente qualidade de representações, especialmente em cenários com poucas amostras.

A comparação entre técnicas que dispensam aumento explícita (CNN-JEPA) e técnicas que a utilizam (SimCLR) demonstra que ambas as abordagens são viáveis, oferecendo flexibilidade no design de sistemas de aprendizado auto-supervisionado. Finalmente, a eficiência do DGAE em termos de compactação abre possibilidades para aplicações onde espaço de armazenamento ou eficiência computacional são críticos.

## 6 | Conclusão

### 6.1 Principais achados

Este trabalho implementou e avaliou diferentes abordagens de aprendizado auto-supervisionado para agrupamento de imagens da base Corel, com foco especial no impacto da aumento por difusão e em técnicas que dispensam aumento explícito.

#### 6.1.1 Implementações Realizadas

1. **Item 2:** Adaptação de modelos pré-treinados (LoRA) para geração de imagens Corel
2. **Item 3:** Treinamento de modelos de difusão do zero (VAE + Latent Diffusion)
3. **Item 4:** Implementação de DGAE para aprendizado de representações latentes
4. **Item 5:** Avaliação de clustering com SimCLR, CNN-JEPA e DGAE

#### 6.1.2 Principais Descobertas

##### Sobre Aumento por Difusão:

- Aumento por difusão pode melhorar qualidade de representações em cenários com poucas amostras
- O impacto varia dependendo da técnica auto-supervisionada utilizada
- Qualidade das gerações é crucial para o sucesso da aumento

##### Sobre Técnicas Sem Aumento Explícito:

- CNN-JEPA demonstra que é possível aprender boas representações sem aumento tradicional

- DGAE mostra que modelos de difusão podem melhorar diretamente representações latentes
- Ambas técnicas são viáveis alternativas a abordagens baseadas em aumentação

**Sobre Eficiência:**

- DGAE alcança representações compactas (2x menor) mantendo qualidade
- CNN-JEPA oferece simplicidade e eficiência sem dependência de modelos externos
- SimCLR mantém simplicidade e velocidade como baseline sólido

### 6.1.3 Contribuições

Este trabalho contribui com:

- Implementação completa de pipeline para avaliação de clustering com múltiplas técnicas
- Comparação sistemática entre técnicas com e sem aumentação por difusão
- Avaliação prática em cenário realista (base Corel com poucas amostras)
- Scripts otimizados para GPU e execução em ambientes cloud
- Documentação completa para reprodução dos experimentos

## 6.2 Limitações e sugestões futuras

### 6.2.1 Limitações

**Dataset:**

- Base Corel relativamente pequena comparada a datasets como ImageNet
- Distribuição desbalanceada entre classes pode afetar avaliação
- Poucas amostras por classe limitam algumas análises estatísticas

**Implementação:**

- Apenas SimCLR foi implementado entre técnicas auto-supervisionadas (BYOL, DINO não foram implementados)
- Alguns hiperparâmetros foram fixados baseados em literatura, não otimizados exaustivamente
- Avaliação focada em K-means; outros algoritmos de clustering não foram explorados

**Recursos:**

- Treinamentos extensivos requerem recursos computacionais significativos
- Alguns experimentos podem ter sido limitados por tempo/memória disponível

### 6.2.2 Sugestões Futuras

**Expansão de Técnicas:**

- Implementar BYOL e DINO para comparação mais abrangente
- Explorar DINO-MultiCrop para avaliação de múltiplas culturas
- Testar combinações de técnicas (ensemble de features)

**Melhorias Metodológicas:**

- Otimização sistemática de hiperparâmetros (grid search, Bayesian optimization)
- Avaliação com múltiplos algoritmos de clustering (hierarchical, DBSCAN, etc.)
- Análise de features com técnicas de redução de dimensionalidade (t-SNE, UMAP)
- Validação cruzada para resultados mais robustos

**Análises Adicionais:**

- Análise de quais classes se beneficiam mais da aumento por difusão
- Estudo de transfer learning: usar modelos treinados em outros datasets
- Análise de interpretabilidade: visualização de quais features são mais importantes
- Estudo de robustez: avaliação com diferentes níveis de ruído/corrupção

**Aplicações Práticas:**

- Aplicar técnicas em outros datasets com poucas amostras
- Integração com pipelines de produção
- Desenvolvimento de ferramentas de visualização interativa
- Otimização para dispositivos com recursos limitados (edge devices)

#### **Extensões Teóricas:**

- Análise teórica de por que DGAE funciona bem com espaço latente menor
- Estudo de convergência e estabilidade de diferentes técnicas
- Desenvolvimento de métricas específicas para avaliação de representações latentes
- Análise de trade-offs teóricos entre compactação e qualidade

### **6.2.3 Lições Aprendidas**

1. **Simplicidade importa:** SimCLR, apesar de simples, pode ser muito eficaz
2. **Contexto é crucial:** A melhor técnica depende do dataset e objetivos
3. **Aumentação não é sempre necessária:** CNN-JEPA mostra alternativas viáveis
4. **Compactação pode ser eficiente:** DGAE demonstra que menor não significa pior
5. **Integração é poderosa:** Usar modelos de difusão para guiar outros modelos abre novas possibilidades

### **6.2.4 Impacto Esperado**

Este trabalho contribui para:

- **Pesquisa:** Melhor compreensão de técnicas auto-supervisionadas e aumento por difusão
- **Prática:** Pipeline completo e documentado para aplicação em outros projetos
- **Educação:** Exemplos práticos de implementação de técnicas state-of-the-art
- **Comunidade:** Código open-source reutilizável e bem documentado

# A | Apêndices: Informações Adicionais

## A.1 Estrutura de Arquivos do Projeto

O projeto está organizado da seguinte forma:

- `codes/`: Contém todos os scripts Python implementados
  - `2A-prepare_corel_dataset.py`: Preparação do dataset
  - `2B-train-lora-corel.py`: Treinamento LoRA
  - `2C-generate-lora-corel.py`: Geração com LoRA
  - `3A-train-vae-corel.py`: Treinamento VAE
  - `3B-train-diffusion-from-scratch-corel.py`: Treinamento difusão
  - `3C-generate-samples-corel.py`: Geração com difusão
  - `4A-train-dgae-corel.py`: Treinamento DGAE
  - `4B-extract-features-corel.py`: Extração features DGAE
  - `5A-simclr_corel.py`: Treinamento SimCLR
  - `5D-cnn-jepa_corel.py`: Treinamento CNN-JEPA
  - `5E-compare-clustering.py`: Comparação de técnicas
- `README_2.md`, `README_3.md`, `README_4.md`, `README_5.md`: Documentação de cada tarefa
- `training_data/corel/`: Dataset preparado
- `features/`: Features extraídas para clustering
- `clustering_results/`: Resultados de comparação

## A.2 Parâmetros de Treinamento Principais

### A.2.1 LoRA (Item 2)

- Base model: runwayml/stable-diffusion-v1-5
- LoRA rank: 4
- LoRA alpha: 4
- Learning rate: 1e-4
- Batch size: 1
- Gradient accumulation: 4
- Epochs: 200 (configurável)
- Resolution: 512x512

### A.2.2 VAE (Item 3)

- Image size: 128x128
- Latent dimension: 128
- Hidden dimensions: [64, 128, 256, 512]
- Learning rate: 1e-4
- Batch size: 16
- KL weight: 1.0
- KL warmup: 150 epochs
- Perceptual weight: 0.03
- Epochs: 300

### A.2.3 Difusão Latente (Item 3)

- Learning rate: 1e-4
- Batch size: 16
- Gradient accumulation: 1

- Image size: 128x128 (após VAE)
- EMA decay: 0.995
- Schedule: linear
- Mixed precision: FP16
- Epochs: 500

#### **A.2.4 DGAE (Item 4)**

- Image size: 256x256
- Latent dimension: 128
- Hidden dimensions: [64, 128, 256, 512]
- Learning rate: 1e-4
- Batch size: 8
- Diffusion guidance weight: 0.1
- Perceptual weight: 0.03
- Epochs: 300

#### **A.2.5 SimCLR (Item 5)**

- Image size: 224x224
- Latent dimension: 128
- Learning rate: 3e-3
- Temperature: 0.5
- Batch size: 32
- Epochs: 100

### A.2.6 CNN-JEPA (Item 5)

- Image size: 224x224
- Feature dimension: 512
- Hidden dimension: 512
- Learning rate: 1e-3
- Batch size: 32
- Epochs: 100

## A.3 Comandos de Execução

### A.3.1 Item 2: LoRA

```
# Preparar dataset
python 2A-prepare-corel_dataset.py \
    --data-dir data/corel --base-dir .

# Treinar LoRA
python 2B-train-lora-corel.py \
    --data-dir training_data/corel/corel_all \
    --output-dir corel_models \
    --epochs 200

# Gerar imagens
python 2C-generate-lora-corel.py \
    --lora-dir corel_models \
    --num-images 16
```

### A.3.2 Item 3: Difusão do Zero

```
# Treinar VAE
python 3A-train-vae-corel.py \
    --data-dir training_data/corel/corel_all \
    --output-dir vae_models \
    --epochs 300

# Treinar difusão
python 3B-train-diffusion-from-scratch-corel.py \
```

```
--vae-checkpoint vae_models/best_model.pt \  
--image-dir training_data/corel/corel_all \  
--output-dir diffusion_models  
  
# Gerar amostras  
python 3C-generate-samples-corel.py \  
    --diffusion-checkpoint diffusion_models/best_model.pt \  
    --vae-checkpoint vae_models/best_model.pt \  
    --num-images 16
```

### A.3.3 Item 4: DGAE

```
# Treinar DGAE  
python 4A-train-dgae-corel.py \  
    --data-dir training_data/corel/corel_all \  
    --lora-dir corel_models \  
    --output-dir dgae_models  
  
# Extrair features  
python 4B-extract-features-corel.py \  
    --model-checkpoint dgae_models/best_model.pt \  
    --data-dir training_data/corel/corel_all \  
    --output features/dgae_features.npy \  
    --extract-labels
```

### A.3.4 Item 5: Clustering

```
# Treinar SimCLR  
python 5A-simclr_corel.py \  
    --data-dir training_data/corel/corel_all \  
    --output-dir simclr_models \  
    --extract-features features/simclr_features.npy  
  
# Treinar CNN-JEPA  
python 5D-cnn-jepa_corel.py \  
    --data-dir training_data/corel/corel_all \  
    --output-dir cnn_jepa_models \  
    --extract-features features/cnn_jepa_features.npy  
  
# Comparar técnicas  
python 5E-compare-clustering.py \  
    --features-dir features \  
    --output-dir clustering_results \  

```

--compare-both

## A.4 Métricas de Clustering

As métricas utilizadas para avaliação são definidas como:

### A.4.1 Adjusted Rand Index (ARI)

O ARI mede a concordância entre os clusters obtidos e as classes verdadeiras, ajustado para o acaso:

$$ARI = \frac{\sum_{ij} \binom{n_{ij}}{2} - [\sum_i \binom{a_i}{2} \sum_j \binom{b_j}{2}] / \binom{n}{2}}{\frac{1}{2} [\sum_i \binom{a_i}{2} + \sum_j \binom{b_j}{2}] - [\sum_i \binom{a_i}{2} \sum_j \binom{b_j}{2}] / \binom{n}{2}}$$

onde  $n_{ij}$  é o número de elementos na classe  $i$  e cluster  $j$ ,  $a_i$  é o número de elementos na classe  $i$ , e  $b_j$  é o número de elementos no cluster  $j$ .

### A.4.2 Normalized Mutual Information (NMI)

O NMI mede a informação mútua normalizada entre clusters e classes:

$$NMI = \frac{2 \cdot I(C; K)}{H(C) + H(K)}$$

onde  $I(C; K)$  é a informação mútua entre classes  $C$  e clusters  $K$ , e  $H(\cdot)$  é a entropia.

### A.4.3 Silhouette Score

O Silhouette Score mede quão similar um objeto é ao seu próprio cluster comparado a outros clusters:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

onde  $a(i)$  é a distância média aos outros pontos no mesmo cluster e  $b(i)$  é a distância média aos pontos no cluster mais próximo.

## A.5 Arquiteturas de Modelos

### A.5.1 Encoder SimCLR/CNN-JEPA

- Conv2d(3, 64, 7x7, stride=2) + BN + ReLU
- MaxPool2d(3x3, stride=2)
- Conv2d(64, 128, 3x3, stride=2) + BN + ReLU
- Conv2d(128, 256, 3x3, stride=2) + BN + ReLU
- Conv2d(256, 512, 3x3, stride=2) + BN + ReLU
- AdaptiveAvgPool2d(1)
- Projection head (SimCLR) ou Linear (CNN-JEPA)

### A.5.2 VAE/DGAE Encoder

- Múltiplas camadas convolucionais com blocos residuais
- Downsampling progressivo (stride=2)
- Dimensões ocultas: [64, 128, 256, 512]
- Saída: Espaço latente de dimensão configurável (128 para DGAE)

### A.5.3 VAE/DGAE Decoder

- Input linear do espaço latente
- Upsampling progressivo com PixelShuffle
- Blocos residuais em cada nível
- Saída: Imagem reconstruída (3 canais RGB)

## A.6 Considerações de Implementação

### A.6.1 Otimizações GPU

Todos os scripts implementam:

- Verificação de disponibilidade CUDA
- `cudnn.benchmark = True`  para convoluções mais rápidas
- `pin_memory = True`  no DataLoader
- `num_workers > 0`  para carregamento paralelo
- Mixed precision (FP16) quando aplicável
- Limpeza periódica de cache CUDA

### A.6.2 Compatibilidade de Checkpoints

- Configurações salvas como dicionários (não objetos) para evitar erros de pickle
- Suporte para carregar checkpoints antigos e novos
- Inferência automática de parâmetros se config não disponível

### A.6.3 Reprodutibilidade

- Seeds fixos para randomização (padrão: 42)
- Ordenação consistente de arquivos
- Determinismo quando possível (com trade-off de performance)

# Bibliography

- [1] Chen, T., Kornblith, S., Norouzi, M., & Hinton, G. (2020). A Simple Framework for Contrastive Learning of Visual Representations. *Proceedings of the 37th International Conference on Machine Learning*, 119, 1597-1607.
- [2] Grill, J.-B., Strub, F., Alché, F., Tallec, C., Richemond, P., Buchatskaya, E., ... & Valko, M. (2020). Bootstrap Your Own Latent: A New Approach to Self-Supervised Learning. *Advances in Neural Information Processing Systems*, 33, 21271-21284.
- [3] Caron, M., Touvron, H., Misra, I., Jégou, H., Mairal, J., Bojanowski, P., & Joulin, A. (2021). Emerging Properties in Self-Supervised Vision Transformers. *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 9650-9660.
- [4] Kalapos, A., & Gyires-Tóth, B. (2025). CNN-JEPA: Self-Supervised Pretraining Convolutional Neural Networks Using Joint Embedding Predictive Architecture. *arXiv preprint arXiv:2408.07514v2*.
- [5] Liu, D., Peng, Y., Tang, H., Chen, Y., Han, C., Ge, Z., Jiang, D., & Liao, M. (2025). DGAE: Diffusion-Guided Autoencoder for Efficient Latent Representation Learning. *arXiv preprint arXiv:2506.09644*.
- [6] Rombach, R., Blattmann, A., Lorenz, D., Esser, P., & Ommer, B. (2022). High-Resolution Image Synthesis with Latent Diffusion Models. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 10684-10695.
- [7] Lai, C.-H., Song, Y., Kim, D., Mitsufuji, Y., & Ermon, S. (2025). The Principles of Diffusion Models: From Origins to Advances. *arXiv preprint arXiv:2510.21890*.
- [8] Kingma, D. P., & Welling, M. (2013). Auto-Encoding Variational Bayes. *arXiv preprint arXiv:1312.6114*.
- [9] Ho, J., Jain, A., & Abbeel, P. (2020). Denoising Diffusion Probabilistic Models. *Advances in Neural Information Processing Systems*, 33, 6840-6851.
- [10] Song, Y., & Ermon, S. (2019). Generative Modeling by Estimating Gradients of the Data Distribution. *Advances in Neural Information Processing Systems*, 32, 11895-11907.

- [11] He, K., Fan, H., Wu, Y., Xie, S., & Girshick, R. (2020). Momentum Contrast for Unsupervised Visual Representation Learning. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 9729-9738.
- [12] Chen, X., Fan, H., Girshick, R., & He, K. (2020). Improved Baselines with Momentum Contrastive Learning. *arXiv preprint arXiv:2003.04297*.
- [13] Radford, A., Kim, J. W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., ... & Sutskever, I. (2021). Learning Transferable Visual Models From Natural Language Supervision. *International Conference on Machine Learning*, 8748-8763.
- [14] Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, E. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
- [15] Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., ... & Chintala, S. (2019). PyTorch: An Imperative Style, High-Performance Deep Learning Library. *Advances in Neural Information Processing Systems*, 32, 8026-8037.